Examen Analyst

Getafe, 6 de marzo de 2026

- Este examen cuenta un 75% para la nota final.
- Una vez obtenida la solución hay que ponerla en la hoja de respuestas adjunta.
- Cada respuesta debe ir en el espacio asignado a ella.
- La corrección es automática: se coge la solución tal cual viene en la hoja de respuestas y se ejecuta. Asegúrate de que la copias correctamente y no cometes ningún error a la hora de pegarla en la hoja de respuestas.
- Una vez terminado el examen, hay que enviar el fichero con las respuestas a estas 2 direcciones:

  marta.moya@puedata.com
  fernando.lafora@puedata.es
- El asunto del mensaje debe ser: Examen SQL - Nombre; por ejemplo: *Examen SQL - Sofía Lobo*.
- El formato de la hoja de respuestas tiene que ser un fichero de texto.
- No hay que cambiar el nombre del fichero con la hoja de respuestas. Si el fichero que se te ha asignado es, por ejemplo, *Lobo_Antúnez_Lucas.txt* hay que adjutarlo con ese mismo nombre.
- Es conveniente que una vez que resuelvas una pregunta copies la respuesta en la hoja.
- Si quieres corregir alguna pregunta después de haber enviado el correo, puedes mandar otro correo con las nuevas soluciones. En este caso, sólo se tendrá en cuenta el último correo.
- El correo debe llegar a las dos direcciones de arriba, como mucho 15 minutos después de haber terminado el examen.

Notas

- El apartado *Comprobación* contiene la salida esperada o bien una serie de instrucciones para comprobar que el ejercicio se ha resuelto correctamente. Si la salida o el resultado de ejecutar estas instrucciones después de haber resuelto el ejercicio no concuerda con el mostrado aquí, la solución no es correcta. **Esto incluye el nombre de las columnas.** Si coincide, no necesariamente la solución es correcta.
- No hay que hacer nada que no se haya pedido.

1 (2,5 puntos)

Enunciado

Ejecutar un query para mostrar para cada empleado estas 5 columnas:

- ➡ Número de empleado
- ➡ Nombre
- ➡ Departamento
- ➡ Sueldo
- ➡ *min_max* con:
  - ▸ La palabra '*Max*' si el empleado tiene el mayor sueldo de su departamento.
  - ▸ La palabra '*Min*' si el empleado tiene el mayor sueldo de su departamento
  - ▸ '---' si no se cumplen ninguna de los dos condiciones anteriores.

La salida debe estar ordenada por *deptno*, *sal*, y *ename*.

Base de datos: *exam*

Tabla: *test_scores*

Herramienta: Impala.

Comprobación

La salida del query debe ser:

empno	ename	deptno	sal	min_max
7110	MILLER	10	1300.00	Min
7050	CLARK	10	2450.00	---
7080	KING	10	5000.00	Max
7000	SMITH	20	800.00	Min
7120	ADAMS	20	1100.00	---
7030	JONES	20	2975.00	---
7100	FORD	20	3000.00	Max
7130	SCOTT	20	3000.00	Max
7090	JAMES	30	950.00	Min
7070	MARTIN	30	1250.00	---
7020	WARD	30	1250.00	---
7060	TURNER	30	1500.00	---
7010	ALLEN	30	2850.00	Max
7040	BLAKE	30	2850.00	Max

2a (1,5 puntos)

Enunciado

Eh hive, crear una tabla, *workers*, de acuerdo a las siguientes condiciones:

1. Antes de crear la tabla hay que comprobar si existe ya; en este caso, hay que borrarla.
2. Tiene que tener 4 columnas:

Nombre	Tipo
`name`	`STRING`
`subordinates`	`ARRAY de STRING`
`languages`	`MAP` con *key* de tipo STRING y *value* de tipo INT
`address`	`STRUCT` con cuatro campos de tipo STRING: no, `street`, `city`, y `zip`

3. Ubicación del directorio hdfs con los datos: */tmp/workers*.
4. Formato de la tabla: `TEXTFIELD`. Los correspondientes separadores para las columnas complejas (`subordinates`, `languages` y `address`), hay que deducirlos de los propios datos (ver el punto 4).
5. Los datos para la tabla están en el fichero *workers.data*:

```
lucas,luisa:pedro:ada,scala-90:java-93:python-80,20:
                                    avenida de sevilla:lugo:27033
luisa,ana,C-40:python-80,40:ferrocarril:zamora:49231
pedro,,lisp-100:pascal-90,90:bronce:madrid:28240
ada,,scala-80:sql-43,45:avenida del mediterrano:palencia:34923
ana,,scala-90,90:avenida de la diagonal:barcelona:08213
```

Una vez creada *workers*, hay que crear otra tabla, *workers_parquet*, de siguiendo estas indicaciones:

1. Tiene que ser *managed*
2. Formato parquet
3. En la propia sentencia de creación, usar un `SELECT` para que *workers_parquet* tenga los mismos datos que *workers*.

Base de datos: *exam*

Tablas: *workers*, *workers_parquet*

Herramienta: hive.

Nota: En la hoja de respuestas, hay que poner dos sentencias sql:

```
CREATE EXTERNAL TABLE workers
  ...
;
```

```
CREATE EXTERNAL TABLE workers
...
;
```

Comprobación

SELECT name, subordinates, languages from workers ;

```
+--------+-------------------------+-------------------------------------+
|  name  |       subordinates      |              languages              |
+--------+-------------------------+-------------------------------------+
| ada    | []                      | {"scala":80,"sql":43}               |
| ana    | []                      | {"scala":90}                        |
| lucas  | ["luisa","pedro","ada"] | {"scala":90,"java":93,"python":80}  |
| luisa  | ["ana"]                 | {"C":40,"python":80}                |
| pedro  | []                      | {"lisp":100,"pascal":90}            |
+--------+-------------------------+-------------------------------------+
```

SELECT address from workers_parquet;

```
+-----------------------------------------------------+
|                       address                       |
+-----------------------------------------------------+
| {"no":"20","street":"avenida de sevilla","city":"lugo","zip":"27033"} |
| {"no":"40","street":"ferrocarril","city":"zamora","zip":"49231"} |
| {"no":"45","street":"avenida del mediterrano","city":"palencia","zip":"34923"} |
| {"no":"90","street":"bronce","city":"madrid","zip":"28240"} |
| {"no":"90","street":"avenida de la diagonal","city":"barcelona","zip":"08213"} |
+-----------------------------------------------------+
```

2b (1 punto)

Esta pregunta depende de la pregunta 2a. No se puede responder si no se ha resuelto esa pregunta.

Una vez creada la tabla *workers_parquet* en 2a, hay que ejecutar una sentencia en Impala que muestre `name`, `key`, `value` y `city` para todos los empleados que tengan el lenguaje scala como `key` del map. La salida debe ordenarse de manera ascendente por *name*.

Base de datos: *exam*

Tabla: *workers_parquet*

Herramienta: Impala.

Comprobación

La salida del query debe ser:

```
+-------+-------+-------+-----------+
| name  | key   | value | city      |
+-------+-------+-------+-----------+
| ada   | scala | 80    | palencia  |
| ana   | scala | 90    | barcelona |
| lucas | scala | 90    | lugo      |
+-------+-------+-------+-----------+
```

3 (2,5 puntos)

Enunciado

Para esta pregunta, hay que usar las tablas *orders*, *order_details*, y *products* de la base de datos *analyst*.

Se pide lo siguiente: Por cada día del mes de agosto de 2008, mostrar el *prod_id* o los *prod_ids* de los productos que más se han vendido en ese día.

La salida ha de estar ordenada por *ddate* y *prod_id*.

Indicaciones

Hay que hacerlo en tres fases.

En la primera, se hace un `GROUP BY` para obtener por cada día y *prod_id*, el número de ventas. Vas a necesitar las funciones *to_date*, *year*, y *month*.

Luego, hay que asignar un rango a las filas basándose en la fecha y el número de productos vendidos.

Finalmente, hay que seleccionar las filas con el rango adecuado.

Base de datos: *analyst*
Tablas: *orders*, *order_details*, y *products*
Herramienta: Impala

Comprobación

```
+------------+---------+-----+
| ddate      | prod_id | cnt |
+------------+---------+-----+
| 2008-08-01 | 1274021 | 4   |
| 2008-08-02 | 1274021 | 4   |
| 2008-08-02 | 1274348 | 4   |
| 2008-08-03 | 1274348 | 6   |
| 2008-08-04 | 1274348 | 6   |
| 2008-08-05 | 1273749 | 4   |
| 2008-08-05 | 1274348 | 4   |
| 2008-08-06 | 1274348 | 6   |
| 2008-08-07 | 1273873 | 5   |
| 2008-08-08 | 1273970 | 4   |
| 2008-08-08 | 1274348 | 4   |
| 2008-08-09 | 1273672 | 4   |
| 2008-08-10 | 1274348 | 6   |
| 2008-08-11 | 1273755 | 4   |
| 2008-08-11 | 1273863 | 4   |
| 2008-08-12 | 1274348 | 5   |
| 2008-08-13 | 1274348 | 7   |
```

```
| 2008-08-14 | 1274348 | 5    |
| 2008-08-15 | 1274348 | 6    |
| 2008-08-16 | 1274348 | 8    |
| 2008-08-17 | 1273758 | 3    |
| 2008-08-17 | 1273771 | 3    |
| 2008-08-17 | 1273973 | 3    |
| 2008-08-17 | 1273985 | 3    |
| 2008-08-17 | 1274080 | 3    |
| 2008-08-17 | 1274483 | 3    |
| 2008-08-18 | 1274348 | 7    |
| 2008-08-19 | 1273989 | 4    |
| 2008-08-20 | 1274348 | 5    |
| 2008-08-21 | 1273972 | 4    |
| 2008-08-22 | 1274348 | 7    |
| 2008-08-23 | 1273677 | 5    |
| 2008-08-24 | 1274348 | 6    |
| 2008-08-25 | 1274348 | 8    |
| 2008-08-26 | 1273654 | 3    |
| 2008-08-26 | 1273675 | 3    |
| 2008-08-26 | 1273737 | 3    |
| 2008-08-26 | 1273754 | 3    |
| 2008-08-26 | 1273759 | 3    |
| 2008-08-26 | 1273796 | 3    |
| 2008-08-26 | 1273859 | 3    |
| 2008-08-26 | 1274172 | 3    |
| 2008-08-26 | 1274190 | 3    |
| 2008-08-26 | 1274348 | 3    |
| 2008-08-26 | 1274748 | 3    |
| 2008-08-27 | 1274348 | 7    |
| 2008-08-28 | 1274348 | 11   |
| 2008-08-29 | 1274348 | 6    |
| 2008-08-30 | 1274348 | 7    |
| 2008-08-31 | 1274348 | 12   |
+------------+---------+-----+
```

4a (1,5 puntos)

Enunciado

La base datos de mysql *analyst_dualcore* contiene una tabla *suppliers*. Mediante *sqoop* hay que volcar los datos de la tabla a HDFS con las siguientes condiciones:

- ➡ El directorio de destino debe ser */tmp/suppliers.*
- ➡ Sólo hay que usar un hilo de ejecución. Es decir, al final de la ejecución del comando *sqoop*, sólo debe haber un fichero bajo */tmp/suppliers*.
- ➡ En HDFS la separación entre los campos debe ser el carácter '+'

- De todas las filas de la tabla, sólo hay que descargar aquellas que cumplan esta condición: El campo *city* debe ser '*Houston*' o '*Los Angeles*'.
- Sólo se deben descargar las siguientes columnas: *supp_id*, *company*, *contact*, y *phone;* y deber ir en el mismo orden.
- *sqoop* no debe fallar aunque el directorio de destino, */tmp/suppliers*, exista ya.
- El programa java que crea sqoop debe situarse en el directorio */tmp* de HDFS y no en el directorio desde donde se ejecuta sqoop.

Comprobación

Después de la ejecución del comando *sqoop*, la salida de siguiente comando tiene que ser como sigue:

$ **hdfs dfs -cat /tmp/suppliers/part-m-00000 | sort**

```
1006+The Connector Company+Leo Irwin+(213) 555-5434
1016+Static Video, Inc.+Betty Whaley+(213) 555-4110
1024+La Brea Distribution Inc.+Jimmy Lozada+(281) 555-4646
1031+Argo Heavy Industries+Monica Ott+(213) 555-7130
1055+SuperGamer Entertainment+Kathryn Neill+(281) 555-2275
1059+United Digistuff Inc.+Mike Hanson+(281) 555-5786
```

4b (1 punto)

Esta pregunta depende de la pregunta 4a. No se puede responder si no se ha resuelto esa pregunta.

Enunciado

Hay que crear una tabla externa, *suppliers*, con las siguientes condiciones:

- Antes de crear la tabla hay que comprobar si existe ya; en este caso, hay que borrarla.
- Tiene que estar ubicada en la base de datos *exam*.
- El directorio con sus datos tiene que ser */tmp/suppliers* (el mismo en el que se han bajado los datos en la pregunta 4a).
- Las columnas de la tabla tienen que ser:

```
id INT,
company STRING,
contact STRING,
phone STRING
```

- El formato de la tabla debe ser el adecuado para poder leer la información que hay en */tmp/suppliers*.

Comprobación

SELECT * FROM suppliers ORDER BY id ;

```
+------+--------------------------+---------------+----------------+
| id   | company                  | contact       | phone          |
```

```
+------+--------------------------+---------------+----------------+
| 1006 | The Connector Company    | Leo Irwin     | (213) 555-5434 |
| 1016 | Static Video, Inc.       | Betty Whaley  | (213) 555-4110 |
| 1024 | La Brea Distribution Inc. | Jimmy Lozada  | (281) 555-4646 |
| 1031 | Argo Heavy Industries    | Monica Ott    | (213) 555-7130 |
| 1055 | SuperGamer Entertainment | Kathryn Neill | (281) 555-2275 |
| 1059 | United Digistuff Inc.    | Mike Hanson   | (281) 555-5786 |
+------+--------------------------+---------------+----------------+
```

Base de datos: *exam*

Tabla: *suppliers*

Herramienta: Impala.