Examen Analyst

Getafe, 4 de marzo de 2026

- Este examen cuenta un 75% para la nota final.
- Una vez obtenida la solución hay que ponerla en la hoja de respuestas adjunta.
- Cada respuesta debe ir en el espacio asignado a ella.
- La corrección es automática: se coge la solución tal cual viene en la hoja de respuestas y se ejecuta. Asegúrate de que lo copias correctamente y no cometes ningún error a la hora de pegarlo en la hoja de respuestas.
- Una vez terminado el examen, hay que enviar el fichero con las respuestas a estas 2 direcciones:

  ~~marta.moya@puedata.com~~
  fernando.lafora@puedata.es
- El asunto del mensaje debe ser: Examen SQL - Nombre; por ejemplo: *Examen SQL - Sofía Lobo*.
- El formato de la hoja de respuestas tiene que ser un fichero de texto.
- No hay que cambiar el nombre del fichero con la hoja de respuestas. Si el fichero que se te ha asignado es, por ejemplo, *Lobo_Antúnez_Lucas.txt* hay que adjutarlo con ese mismo nombre.
- Es conveniente que una vez que resuelvas una pregunta copies la respuesta en la hoja.
- Si quieres corregir alguna pregunta después de haber enviado el correo, puedes mandar otro correo con las nuevas soluciones. En este caso, sólo se tendrá en cuenta el último correo.
- El correo debe llegar a las dos direcciones de arriba, como mucho 15 minutos después de haber terminado el examen.

Notas

- El apartado *Comprobación* contiene una serie de instrucciones para comprobar que el ejercicio se ha resuelto correctamente. Si el resultado de ejecutar estas instrucciones después de haber resuelto el ejercicio no concuerda con el mostrado aquí, la solución no es correcta. Si coincide, no necesariamente la solución es correcta.
- No hay que hacer nada que no se haya pedido.

1 (2,5 puntos)

Enunciado

Ejecutar un query para mostrar para cada estudiante estas 5 columnas:

- Su nombre
- La materia de la que se examinó
- Su nota
- La media de la nota de todos los estudiantes de la misma materia
- La palabra 'Above' si el estudiante superó la media o '-----' si no superó la media.

Base de datos: *exam*

Tabla: *test_scores*.

Comprobación

La salida del query debe ser:

```
+---------+--------+-------+-------+--------+
| name    | test   | score | avg   | above? |
+---------+--------+-------+-------+--------+
| Tatiana | SQL    | 87    | 65.25 | Above  |
| Steve   | SQL    | 75    | 65.25 | Above  |
| Tracy   | SQL    | 56    | 65.25 | -----  |
| Robert  | SQL    | 43    | 65.25 | -----  |
| Tracy   | Tuning | 88    | 71.25 | Above  |
| Steve   | Tuning | 83    | 71.25 | Above  |
| Tatiana | Tuning | 83    | 71.25 | Above  |
| Robert  | Tuning | 31    | 71.25 | -----  |
+---------+--------+-------+-------+--------+
```

Solución

```
USE exam ;

SELECT
  name, test, score,
  AVG(score) OVER (PARTITION BY test ) avg,
  CASE
    WHEN score > AVG(score) OVER (PARTITION BY test ) THEN "Above"
    ELSE '-----'
  END AS 'Above?'
FROM test_scores
ORDER BY test, score DESC ;
```

2 (2,5 puntos)

Enunciado

Crear una tabla, *customers*, de acuerdo a las siguientes condiciones:

1. Con 4 columnas:

Nombre	Tipo
`cust_id`	`INT`
`name`	`STRING`
`phones`	`MAP` con tipo de teléfono como *key* y número de teléfono como *value*
`address`	`STRUCT` con tres campos de tipo STRING: `street`, `city`, y `zipcode`

2. Ubicación del directorio hdfs con los datos: */tmp/customers*.

3. Formato de la tabla: `TEXTFIELD`. Los correspondientes separadores para las columnas complejas (`phones` y `address`), hay que deducirlos de los propios datos (ver el siguiente punto).

4. Los datos para la tabla están en el fichero *customers.data*:

```
32,violeta,home/669224521*work/619999292,gran via*badajoz*06903
42,paloma,work/969224523,paseo del molino*huelva*21934
32,azucena,mobile/892345691,calle de la espiga*palencia*34592
32,juan,home/669334520*mobile/666669292,gran via*badajoz*06903
32,hugo,home/369224521,chile*madrid*28903
```

Después de crear la tabla, hay que ejecutar un query en hive que produzca lo siguiente:

```
+----------+---------------------+-----------+---------+------------+
|   name   |       street        |   city    |  type   |   number   |
+----------+---------------------+-----------+---------+------------+
| azucena  | calle de la espiga  | palencia  | mobile  | 892345691  |
| hugo     | chile               | madrid    | home    | 369224521  |
| juan     | gran via            | badajoz   | home    | 669334520  |
| juan     | gran via            | badajoz   | mobile  | 666669292  |
| paloma   | paseo del molino    | huelva    | work    | 969224523  |
| violeta  | gran via            | badajoz   | home    | 669224521  |
| violeta  | gran via            | badajoz   | work    | 619999292  |
+----------+---------------------+-----------+---------+------------+
```

Es decir, por cada *customer* hay que mostrar una línea por cada teléfono que tenga con la información de arriba. Por ejemplo, *violeta* tiene dos teléfonos y hay dos líneas en la salida con la información de *violeta*.

La salida está ordenada por *name* y *type*.

Base de datos: *exam*

Tabla: *customers*

Nota: En la hoja de respuestas, hay que poner dos sentencias sql: una con la creación de la tabla y otra con el query. Por ejemplo:

```
CREATE EXTERNAL TABLE customers (
  cust_id INT,
  ...
)
```

```
... ;


SELECT ...
FROM customers
... ;
```

Comprobación

La salida del query debe ser como se indica en el enunciado.

Solución

```
USE exam ;

DROP TABLE IF EXISTS customers ;

CREATE EXTERNAL TABLE customers (
  cust_id INT,
  name STRING,
  phones MAP<STRING, STRING>,
  address STRUCT<
    street:STRING,
    city:STRING,
    zipcode:STRING>
)
ROW FORMAT DELIMITED
  FIELDS TERMINATED BY ','
  COLLECTION ITEMS TERMINATED BY '*'
  MAP KEYS TERMINATED BY '/'
STORED AS TEXTFILE
LOCATION '/tmp/customers' ;

!sh hdfs dfs -put -f customers.data /tmp/customers

SELECT name, address.street, address.city, p.key AS type, p.value AS number
FROM customers
  LATERAL VIEW OUTER explode( phones ) p
ORDER BY name, type;
```

3 (2,5 puntos)

Enunciado

Cada fila de la tabla *ads* de la base de datos *analyst* contiene la fecha de la publicación de un anuncio (*display_date*) y el url en donde se publicó (*display_site*)

Se pide lo siguiente: Por cada fecha (*display_date*) mostrar el sitio (*display_site*) que menos anuncios haya tenido (columna *num*).

La salida debe estar ordenada por *display_date* y luego por *display_site*.

Si el mínimo para una fecha concreta lo cumplen varios sitios, hay que mostrar todos esos sitios y no sólo uno. Por ejemplo, en la salida que se muestra a continuación, para el día 05/10/2103 hay 3 sitios que han tenido el mínimo de anuncios, 76.

Base de datos: *analyst*
Tabla: *ads*

Comprobación

display_site	display_date	num
betamaxholdouts.example.com	05/01/2013	72
dealgamer.example.com	05/02/2013	66
homemechanic.example.com	05/03/2013	66
ccpstudygroup.example.com	05/04/2013	77
betamaxholdouts.example.com	05/05/2013	67
lawnphotos.example.com	05/06/2013	77
bitfancy.example.com	05/07/2013	73
dbacentral.example.com	05/08/2013	69
homemechanic.example.com	05/09/2013	68
bitfancy.example.com	05/10/2013	76
butterworld.example.com	05/10/2013	76
ccpstudygroup.example.com	05/10/2013	76
grillingtips.example.com	05/11/2013	72
bassoonenthusiast.example.com	05/12/2013	64
bassoonenthusiast.example.com	05/13/2013	64
lawnphotos.example.com	05/14/2013	72
butterworld.example.com	05/15/2013	73
betamaxholdouts.example.com	05/16/2013	76
megawave.example.com	05/16/2013	76
granolaworld.example.com	05/17/2013	66
coffeenews.example.com	05/18/2013	70
megawave.example.com	05/19/2013	75
masterbaker.example.com	05/20/2013	74
masterbaker.example.com	05/21/2013	75
megatips.example.com	05/21/2013	75
granolaworld.example.com	05/22/2013	61
grillingtips.example.com	05/23/2013	68
bassoonenthusiast.example.com	05/24/2013	62
megatips.example.com	05/25/2013	74
homemechanic.example.com	05/26/2013	72
bitsizzler.example.com	05/27/2013	78
megatips.example.com	05/27/2013	78
megatips.example.com	05/28/2013	68
architectworld.example.com	05/29/2013	72
ccpstudygroup.example.com	05/29/2013	72
architectworld.example.com	05/30/2013	70
butterworld.example.com	05/31/2013	76

```
| jokeport.example.com          | 05/31/2013   | 76   |
+-------------------------------+--------------+-----+
```

Solución

```
USE analyst ;

WITH ads_count AS (
  SELECT display_site, display_date, COUNT(display_date) AS num
  FROM ads
  GROUP BY display_site, display_date
)
SELECT display_site, display_date, num
FROM (
  SELECT display_site, display_date, num,
         rank() OVER (PARTITION BY display_date ORDER BY num ) AS dayrank
  FROM ads_count
  ORDER BY display_date, dayrank) sq
WHERE dayrank = 1
ORDER BY display_date, display_site ;
```

4a (1,5 puntos)

Enunciado

La base datos de mysql *analyst_dualcore* contiene una tabla *employees*. Mediante *sqoop* hay que volcar los datos de la tabla a HDFS con las siguientes condiciones:

- El directorio de destino debe ser */tmp/employees.*
- Sólo hay que usar un hilo de ejecución. Es decir, al final de la ejecución del comando *sqoop*, sólo debe haber un fichero bajo */tmp/employees*.
- En HDFS la separación entre los campos debe ser el carácter ':'
- De todas las filas de la tabla, sólo hay que descargar aquellas que cumplan estas dos condiciones: 1) *state* debe ser igual a *OR* y 2) *fname* debe empezar por *An*.
- Sólo se deben descargar las siguientes columnas: *emp_id*, *fname*, *lname*, *city*, y *state;* y deber ir en el mismo orden.
- *sqoop* no debe fallar aunque el directorio de destino, */tmp/employees*, exista ya.
- El programa java que crea sqoop debe situarse en el directorio */tmp* de HDFS y no en el directorio desde donde se ejecuta sqoop.

Comprobación

Después de la ejecución del comando *sqoop*, comprueba la salida de los siguientes comandos:

```
$ hdfs dfs -cat /tmp/employees/part-m-00000 | wc -l
45
```

$ hdfs dfs -cat /tmp/employees/part-m-00000 | sort | head -5

```
AA9074240:Antoinette:Aguirre:Lexington:OR
AA9081691:Andrea:Aldridge:Florence:OR
AB3663868:Andrea:Buckley:Willamina:OR
AB3876665:Andy:Berg:Bend:OR
AB4872845:Andrea:Birch:North Bend:OR
```

Solución

```
#!/bin/zsh
sqoop import \
  -m 1 \
  --connect jdbc:mysql://localhost/analyst_dualcore \
  --username training --password training \
  --fields-terminated-by ':' \
  --warehouse-dir /tmp \
  --columns "emp_id, fname, lname, city, state" \
  --where "state='OR' AND fname LIKE 'An%'" \
  --delete-target-dir \
  --outdir /tmp \
  --table employees
```

4b (1 punto)

Esta pregunta depende de la pregunta 4a. No se puede responder si no se ha resuelto esa pregunta.

Enunciado

Hay que crear una tabla externa, *employees*, con las siguientes condiciones:

- Tiene que estar ubicada en la base de datos *exam*.
- El directorio con sus datos tiene que ser */tmp/employees* (el mismo en el que se han bajado los datos en la pregunta 4a).
- Las columnas de la tabla tienen que ser:

  ```
  emp_id STRING,
  fname STRING,
  lname STRING,
  city STRING,
  state CHAR(2)
  ```

- El formato de la tabla debe ser el adecuado para poder leer la información que hay en */tmp/employees*.

Comprobación

```
SELECT * FROM exam.employees
ORDER BY lname
LIMIT 10 ;
+-----------+------------+----------+-------------+-------+
| emp_id    | fname      | lname    | city        | state |
+-----------+------------+----------+-------------+-------+
```

```
| AA9074240 | Antoinette | Aguirre   | Lexington    | OR     |
| AA9081691 | Andrea     | Aldridge  | Florence     | OR     |
| AB9569507 | Ann        | Bahena    | Port Orford  | OR     |
| AB3876665 | Andy       | Berg      | Bend         | OR     |
| AB4872845 | Andrea     | Birch     | North Bend   | OR     |
| AB7757352 | Andrea     | Brady     | Colton       | OR     |
| AB3663868 | Andrea     | Buckley   | Willamina    | OR     |
| AC9392117 | Anna       | Cahill    | Ontario      | OR     |
| AC8572072 | Anthony    | Cantu     | Sheridan     | OR     |
| AC6710901 | Anton      | Cardwell  | Clackamas    | OR     |
+-----------+------------+----------+-------------+-------+
```

```
SELECT COUNT(1) cnt FROM exam.employees ;
+-----+
| cnt |
+-----+
| 45  |
+-----+
```

Solución

```
USE exam ;

DROP TABLE IF EXISTS employees ;

CREATE EXTERNAL TABLE employees (
  emp_id STRING,
  fname STRING,
  lname STRING,
  city STRING,
  state CHAR(2)
)
ROW FORMAT DELIMITED
  FIELDS TERMINATED BY ':'
STORED AS TEXTFILE
LOCATION '/tmp/employees' ;

SELECT * FROM employees ;

SELECT COUNT(1) cnt FROM employees ;
```